




2026

SCY1101-800D

Programación Para la Ciencia de Datos

Proyecto “Student Depression”

Experiencia de Aprendizaje 2

Modelos de aprendizaje automático

Abel Aravena – Benjamín Aravena – Gabriel Castillo

Contenido

Introducción	2
Caso en desarrollo	3
Marco metodológico	4
Estructura de Proyecto	6
Fase 1: Enfoque General	7
Fase 2: Preparación de Datos	8
Fase 3: Hiperparámetros para Optimización	9
Fase 4: Modelado Supervisado	10
Fase 5: Evaluación de Modelos	11
Fase 6: Modelado NO Supervisado	13
Conclusiones	14

Introducción

En los últimos años, la salud mental en estudiantes se ha convertido en una problemática de creciente relevancia a nivel global, impactando tanto el rendimiento académico como el bienestar general de las personas. En este contexto, el análisis de datos surge como una herramienta clave para identificar patrones de riesgo y apoyar la toma de decisiones informadas en entornos educativos.

El presente proyecto corresponde a la segunda etapa del desarrollo de una solución de ciencia de datos, cuyo objetivo es construir y evaluar **modelos de Machine Learning** capaces de predecir la presencia de depresión en estudiantes, a partir de variables académicas, personales y contextuales. Este trabajo se basa en un dataset previamente procesado y documentado, en el cual se realizó un análisis exploratorio, limpieza de datos y transformación de variables, asegurando su calidad y adecuación para etapas posteriores de modelado.

Esta segunda fase contempla un ciclo completo de modelado, incluyendo la implementación de algoritmos de aprendizaje supervisado y no supervisado, la evaluación comparativa de su desempeño y la optimización de hiperparámetros.

Se emplea un enfoque híbrido: por una parte, se emplean modelos supervisados para predecir la variable target (depresión), y por otra, técnicas no supervisadas para explorar la segmentación de los estudiantes y enriquecer el análisis. Esta combinación permite obtener una visión más completa del problema, integrando capacidad predictiva con interpretación estructural de los datos.

Finalmente, este informe presenta el diseño experimental, los resultados obtenidos y su respectivo análisis, con el fin de evaluar el desempeño de los modelos implementados y extraer conclusiones relevantes tanto desde una perspectiva técnica como aplicada.

Caso en desarrollo

El caso escogido encuentra su origen en el dataset [Student Depression Dataset](#), publicado en Kaggle por el usuario Shodolamu Opeyemi en 2025.

Este dataset consiste en un único archivo CSV (archivo separado por comas), originalmente compuesto de un total de 18 columnas de datos y 27901 registros (filas), con los cuales se busca determinar una tasa de depresión en estudiantes de diferentes ciudades.

El detalle de cada una de las columnas del dataset es desplegado a continuación:

- ~~ID: Identificador único para cada estudiante.~~
- **Age:** Edad del estudiante.
- **Gender:** Género del estudiante (ej: Masculino, Femenino).
- ~~City: Ciudad donde reside el estudiante.~~
- **CGPA:** Promedio de notas a lo largo de toda su carrera.
- **Sleep Duration:** Duración promedio de las horas de sueño.
- ~~Profession: Profesión del estudiante (si aplica).~~
- ~~Work Pressure: Presión que sufre desde su trabajo (si aplica) (medido de 1 a 5).~~
- **Academic Pressure:** Presión que sufre en el ámbito académico (medido de 1 a 5).
- **Study Satisfaction:** Índice de satisfacción respecto de sus estudios (medido de 1 a 5).
- ~~Job Satisfaction: Índice de satisfacción respecto de su trabajo (si aplica) (medido de 1 a 5).~~
- **Dietary Habits:** Indicador de hábitos alimenticios (ej: saludable, no saludable).
- **Degree:** Grado académico del estudiante.
- **Have you ever had suicidal thoughts?:** ¿El estudiante ha tenido pensamientos suicidas? (sí / no)
- **Work / Study hours:** Horas promedio de trabajo o estudio diarios.
- **Financial Stress:** Índice de estrés financiero (medido de 1 a 5).
- **Family history of mental illness:** ¿La familia del estudiante posee historial de enfermedades mentales? (sí / no).
- **Depression:** Variable target que, en base a todas las columnas anteriores, determina entonces si el estudiante posee o no posee depresión (sí / no).

Durante la fase anterior, se realizó una limpieza de estos datos, logrando conservar un **99.7% de la información original** y eliminando únicamente el 0.3% de los datos (84 filas). En cuanto al featurig, se optó por descartar las columnas tachadas en este documento, puesto que la información que aportaban estaba incompleta y/o no resultó relevante para los objetivos de este proyecto.

Marco metodológico

1. Enfoque general

Se define como objetivo principal la construcción de modelos capaces de predecir la presencia de depresión en estudiantes, a partir de variables académicas, personales y contextuales. Para ello, se utiliza un enfoque híbrido:

- **Aprendizaje supervisado**, orientado a la predicción del target (Depression).
- **Aprendizaje no supervisado**, enfocado en identificar patrones, segmentación de datos y reducción de dimensionalidad.

Este enfoque permite complementar la capacidad predictiva con una comprensión más profunda de los datos.

2. Preparación de datos

El dataset utilizado corresponde a una versión previamente procesada, en la cual se realizaron tareas de limpieza, imputación de valores nulos, eliminación de variables irrelevantes y codificación de variables categóricas.

Adicionalmente, se aplicaron técnicas de transformación mediante un pipeline de Scikit-learn, incluyendo:

- Codificación de variables categóricas (One-Hot Encoding y codificación binaria).
- Estandarización de variables numéricas mediante StandardScaler.
- Conservación de la variable objetivo sin transformación.

Este proceso garantiza consistencia, reproducibilidad y adecuación de los datos para el entrenamiento de modelos.

3. Optimización de hiperparámetros

Se aplicarán técnicas de optimización para mejorar el rendimiento de los modelos propuestos para el proyecto:

- **GridSearchCV**: para exploración exhaustiva de combinaciones de hiperparámetros.
- **RandomizedSearchCV**: para exploración eficiente en espacios de búsqueda más amplios.

Este proceso será documentado y analizado, evaluando el impacto de los hiperparámetros en el desempeño final de cada modelo.

4. Modelado supervisado

Se implementan múltiples algoritmos de clasificación, seleccionados en función de la naturaleza del problema y las características del dataset:

- **Regresión Logística:** utilizada como modelo base por su interpretabilidad y eficiencia en problemas de clasificación binaria.
- **Random Forest:** modelo de ensamble capaz de capturar relaciones no lineales y manejar adecuadamente variables categóricas codificadas.

Todos los modelos serán implementados utilizando pipelines, asegurando coherencia en el flujo de datos.

5. Evaluación de modelos

La evaluación del desempeño de los modelos se realizará mediante validación cruzada, con el objetivo de obtener estimaciones robustas y generalizables.

Se utilizarán múltiples métricas de evaluación:

- Accuracy
- Precision
- Recall
- F1-score

Dado el contexto del problema, se prioriza el análisis del recall, buscando minimizar los falsos negativos, es decir, casos en los cuales un estudiante con depresión no es correctamente identificado.

6. Modelado no supervisado

Con el objetivo de complementar el análisis, se aplican técnicas no supervisadas:

- **K-Means Clustering:** para identificar segmentos de estudiantes con características similares y analizar su relación con la variable de depresión.
- **Análisis de Componentes Principales (PCA):** para reducir la dimensionalidad del dataset, facilitar la visualización y evaluar posibles mejoras en el rendimiento de los modelos supervisados.

Los resultados obtenidos serán utilizados tanto para análisis exploratorio como para potencial incorporación de nuevas variables en modelos supervisados.

7. Análisis e integración de resultados


Finalmente, se realizará un análisis comparativo de los modelos implementados, considerando tanto métricas cuantitativas como interpretaciones cualitativas.

Se evaluará además el impacto de las técnicas no supervisadas en el proceso de modelado, particularmente en la mejora del desempeño predictivo y en la comprensión de patrones relevantes.

Este análisis permitirá seleccionar el modelo más adecuado y formular conclusiones fundamentadas, junto con recomendaciones para futuras mejoras.

Estructura de Proyecto

Para organizar este proyecto de forma exitosa, se ha propuesto la siguiente estructura de carpetas:



- ✓ En `data/`, se almacenarán los datos antes y después de procesar.
- ✓ En `notebooks/`, se guardarán los archivos `.ipynb` del pipeline.
- ✓ En `src/`, se tendrá código reutilizable (clave para reproducibilidad).
- ✓ En `outputs/`, se guardarán gráficos, reportes y métricas de utilidad.
- ✓ En `docs/`, se tendrá la documentación del proyecto.

Fase 1: Enfoque General

El presente proyecto se fundamenta en la necesidad de abordar la salud mental en el entorno académico mediante el uso de analítica avanzada. El objetivo central es la construcción y validación de modelos predictivos capaces de identificar la presencia de depresión en estudiantes, utilizando como insumo un conjunto de 24 variables que abarcan dimensiones académicas, personales y contextuales. Este enfoque permite transformar datos brutos en una herramienta de tamizaje preventivo para la toma de decisiones institucionales.

Para garantizar la robustez del análisis, se ha adoptado un enfoque metodológico híbrido. En primera instancia, se emplea el **Aprendizaje Supervisado**, centrado en el entrenamiento de algoritmos de clasificación para predecir la variable objetivo (*Depression*). Complementariamente, se integra el **Aprendizaje No Supervisado** para la exploración de estructuras latentes, permitiendo segmentar a la población estudiantil en perfiles de riesgo y reducir la dimensionalidad de los datos. Esta dualidad metodológica asegura no solo una alta capacidad predictiva, sino también una comprensión profunda de los patrones de comportamiento asociados al fenómeno en estudio.

Al igual que en la fase pasada, se estableció un nuevo repositorio en **GitHub** con una estructura de ramas (Git Flow) para el trabajo colaborativo y el control de versiones eficiente.

ACLARACIÓN IMPORTANTE

Este proyecto tiene fines exclusivamente académicos y exploratorios, sin constituir una herramienta de diagnóstico ni reemplazar la evaluación o asesoramiento de profesionales de la salud mental.

Fase 2: Preparación de Datos

La calidad de las predicciones depende directamente de la integridad del dataset. Tras un exhaustivo Análisis Exploratorio de Datos (EDA), se ejecutó una estrategia de limpieza orientada a eliminar el "ruido" estadístico y asegurar la relevancia de las variables. Los hitos principales incluyeron el tratamiento de valores nulos en la variable *Financial Stress* mediante la mediana, y el filtrado de valores atípicos en *Age* y *CGPA* aplicando el método de tres desviaciones estándar (3-sigma). Asimismo, se descartaron columnas con nula variabilidad o alta redundancia, como *Profession*, *Job Satisfaction* y *Work Pressure*, logrando conservar un 99.7% de la muestra original (27,817 registros de alta calidad).

Para garantizar la consistencia y la reproducibilidad en la fase de producción, la transformación de datos se centralizó en un **Pipeline de Scikit-Learn**. Este flujo automatizado aplicó *One-Hot Encoding* para variables nominales (como *Gender* y *Degree*) y una codificación binaria para variables dicotómicas, mientras que las variables numéricas fueron normalizadas mediante *StandardScaler*. Este proceso de ingeniería no solo estabilizó las escalas de los datos para evitar sesgos en los algoritmos, sino que resultó en una matriz técnica de 25 columnas optimizadas, permitiendo que el modelo capture relaciones complejas sin comprometer la eficiencia computacional.

Para garantizar un procesamiento consistente, se construyó un pipeline utilizando Scikit-Learn. Esta estructura permite aplicar diferentes tratamientos según la naturaleza de la variable en un solo flujo de ejecución:

- **Codificación Categórica Nominal (OneHotEncoder):** Se aplicó a *Gender*, *Sleep Duration*, *Dietary Habits* y *Degree*. Se utilizó el parámetro `drop='first'` para evitar la multicolinealidad.
- **Codificación Binaria (OrdinalEncoder):** Las variables "Have you ever had suicidal thoughts ?" y "Family history of mental illness" fueron transformadas mediante un codificador ordinal, permitiendo que el modelo interprete la respuestas yes/no de forma binaria (0 y 1).
- **Normalización Numérica (StandardScaler):** Variables como *Age*, *Academic Pressure*, *CGPA*, *Study Satisfaction*, *Work/Study Hours* y *Financial Stress* fueron estandarizadas. Este paso es crítico, ya que lleva todas las escalas a una media 0 y desviación estándar 1, evitando que variables con números grandes (como la edad) dominen sobre variables de rango pequeño (como el CGPA).
- Se implementó una configuración de `remainder='passthrough'` en el transformador de columnas. Esto permitió mantener la variable **Depression** dentro del flujo de datos sin someterla a transformaciones innecesarias, asegurando que el dataset final conserve su variable "target" para la etapa de entrenamiento del modelo.

Fase 3: Hiperparámetros para Optimización

La optimización de hiperparámetros es una etapa crítica para maximizar la capacidad de generalización de los modelos y evitar el subajuste o sobreajuste. En este proyecto, se implementó una estrategia diferenciada para los dos algoritmos principales, buscando un equilibrio entre la exhaustividad de la búsqueda y la eficiencia operativa. Para la **Regresión Logística**, se utilizaron tanto GridSearchCV como RandomizedSearchCV, permitiendo una exploración detallada de los parámetros de regularización y los diferentes tipos de penalización (*penalty*), logrando converger hacia una configuración que balancea la simplicidad del modelo con su precisión.

```
{  
  "C": 0.5994842503189409,  
  "penalty": "l2"  
}
```

```
{  
  "penalty": "l2",  
  "C": 0.615848211066026  
}
```

En el caso del modelo **Random Forest**, la complejidad del espacio de búsqueda (profundidad del árbol, número de estimadores, criterios de división) presentó un **desafío computacional significativo**. Por este motivo, se optó exclusivamente por el uso de RandomizedSearchCV. Esta técnica permitió explorar de manera inteligente y estocástica una amplia gama de combinaciones en una fracción del tiempo que requeriría una búsqueda por grilla tradicional, garantizando un rendimiento óptimo sin agotar los recursos de procesamiento.

```
{  
  "criterion": "entropy",  
  "max_depth": 14,  
  "min_samples_split": 10,  
  "n_estimators": 98  
}
```

Finalmente, los mejores parámetros identificados para cada modelo fueron exportados en formato JSON. Esta práctica de ingeniería asegura la **reproducibilidad total** del experimento, permitiendo que los modelos optimizados puedan ser recreados y desplegados en entornos de producción sin la necesidad de repetir el costoso proceso de búsqueda. El impacto de esta fase se traduce directamente en una mejora medible en la estabilidad de las métricas de evaluación, especialmente en la consistencia del *F1-score*.

Fase 4: Modelado Supervisado

En esta etapa se implementaron dos arquitecturas de clasificación robustas, seleccionadas por su complementariedad técnica y su idoneidad para el análisis de salud mental. El proceso se estandarizó mediante el uso de **Pipelines de Scikit-Learn**.

El primer modelo implementado fue la **Regresión Logística**, seleccionada como el "modelo base". Su inclusión es fundamental debido a su alta interpretabilidad y eficiencia en problemas de clasificación binaria. Al ser un modelo lineal, permite establecer una referencia clara de rendimiento y facilita la comprensión de cómo cada variable contribuye a la probabilidad de riesgo.

```
▼ Pipeline ⓘ ⓘ
Pipeline(steps=[('model',
                  LogisticRegression(C=0.5994842503189409, random_state=42,
                                     solver='liblinear'))])
▶ LogisticRegression ⓘ
```


Por otro lado, se implementó un **Random Forest**, un modelo de ensamble basado en múltiples árboles de decisión. Este algoritmo fue elegido por su capacidad para capturar relaciones no lineales y complejas interacciones entre variables que un modelo lineal podría omitir. La combinación de ambos enfoques asegura que el proyecto cuente con una base sólida de comparación y una herramienta de alta capacidad predictiva para el despliegue final.

```
▼ Pipeline ⓘ ⓘ
Pipeline(steps=[('model',
                  RandomForestClassifier(criterion='entropy', max_depth=14,
                                       min_samples_split=10, n_estimators=98,
                                       random_state=42))])
▶ RandomForestClassifier ⓘ
```


Los modelos entrenados fueron posteriormente almacenados utilizando **joblib** para permitir su reutilización en etapas posteriores de evaluación y análisis.

Fase 5: Evaluación de Modelos


El desempeño de los modelos fue evaluado mediante múltiples métricas que permiten observar el fenómeno desde distintos ángulos: *Accuracy*, *Precision*, *Recall* y *F1-score*. Dado que el diagnóstico de depresión es un tema de alta sensibilidad social y médica, el criterio de éxito principal se estableció en la optimización del **Recall**. Esta decisión busca minimizar los falsos negativos, garantizando que la institución sea capaz de identificar a la mayor cantidad posible de estudiantes en riesgo real, incluso a costa de un incremento controlado en las alertas preventivas (falsos positivos).



Tras el análisis, el modelo **Random Forest** fue seleccionado como ganador. Aunque ambos algoritmos presentaron una exactitud cercana al 85%, el Random Forest alcanzó un **Recall de 0.8960**, superando a la Regresión Logística. Esto significa que el modelo es capaz de capturar correctamente al 89.6% de los estudiantes con depresión. La **Matriz de Confusión** confirma esta tendencia, mostrando una alta concentración de verdaderos positivos y una distribución de errores que favorece la seguridad del estudiante, alineándose con los objetivos preventivos de la institución.




Para asegurar que estos resultados no fueran producto del azar en la partición de los datos, se ejecutó una **Validación Cruzada (K-Fold)**. Los resultados demostraron una estabilidad notable, con una desviación estándar inferior al 0.005 para ambos modelos. El Random Forest, en particular, destacó por su bajísima variabilidad (Std: 0.002), lo que garantiza que el sistema sea confiable y robusto al enfrentarse a nuevos perfiles estudiantiles. Finalmente, se analizó la importancia de las variables (*Feature Importance*), revelando qué factores (como los pensamientos suicidas, o estrés financiero) son los principales disparadores del riesgo, otorgando al modelo una capa de interpretabilidad esencial para la acción institucional.



Fase 6: Modelado NO Supervisado

Además de la predicción supervisada, se exploraron técnicas no supervisadas para identificar perfiles latentes de estudiantes.

Esta fase buscó identificar patrones de comportamiento y agrupaciones naturales sin sesgos diagnósticos previos. Al eliminar deliberadamente la variable objetivo (*Depression*) de este análisis, se permitió que los algoritmos revelaran la estructura latente de los datos, facilitando una comprensión más holística de los perfiles estudiantiles.



Para la segmentación de los datos, se utilizó el algoritmo **K-Means Clustering**. La selección del número óptimo de grupos fue el resultado de un análisis técnico riguroso: el **Método del Codo** mostró una estabilización clara en la inercia a partir de los dos grupos, decisión que fue respaldada por el **Coeficiente de Silhouette**, el cual alcanzó su valor más sólido con $k = 2$. Este resultado sugiere que, a nivel estructural, la muestra se divide en dos grandes arquetipos de estudiantes con características marcadamente diferenciadas en sus métricas académicas, hábitos de sueño y niveles de presión reportados.

Para facilitar la interpretación y visualización de estos hallazgos, se empleó el **Análisis de Componentes Principales (PCA)**, reduciendo el dataset a solo dos ejes principales que conservan la mayor varianza de la información. Esta técnica permitió mostrar el "espacio estudiantil" en un plano bidimensional, evidenciando la distribución de los clusters e identificando las zonas de intersección donde los perfiles son más ambiguos. Los resultados del modelado no supervisado no solo validaron la cohesión del dataset, sino que sirvieron como un marco de referencia esencial para entender que el riesgo de depresión no es un evento aislado, sino que está vinculado a configuraciones específicas del entorno y comportamiento del estudiante.

Conclusiones

El trabajo realizado en esta experiencia 2 resultó en un gran avance para la detección temprana de riesgos en salud mental. Al integrar los hallazgos de las fases supervisadas y no supervisadas, se concluye que el modelo de **Random Forest** es la solución más robusta para el despliegue institucional. Su capacidad para identificar al **89.6% de los casos positivos**, sumada a una estabilidad estadística superior, lo posiciona como un sistema de tamizaje altamente confiable que prioriza la seguridad del estudiante por sobre la precisión puramente matemática.

La integración de técnicas no supervisadas (K-Means y PCA) fue fundamental para validar la estructura del dataset. El descubrimiento de dos macro-segmentos estudiantiles confirma que el riesgo de depresión no es aleatorio, sino que está estrechamente vinculado a perfiles con alta carga académica y presión financiera. Esta "visión de 360 grados" permitió que el modelo supervisado no solo prediga un estado, sino que se asiente sobre una base de datos cuya segmentación natural es coherente con la realidad académica. El análisis de importancia de variables (*Feature Importance*) cierra este ciclo, otorgando interpretabilidad al modelo al señalar los factores externos sobre los cuales la institución puede intervenir proactivamente.

Como resultado final, se formulan las siguientes recomendaciones futuras:

- Utilizar el modelo de Random Forest para generar alertas preventivas en el sistema de gestión académica, derivando a los estudiantes identificados a entrevistas de orientación psicológica.
- Se recomienda la actualización semestral del dataset para capturar cambios en las tendencias generacionales y ajustar los hiperparámetros mediante *RandomizedSearchCV* para mantener la vigencia del sistema.
- El sistema debe ser utilizado estrictamente como una herramienta de apoyo preventivo y no como un diagnóstico clínico definitivo, asegurando siempre la confidencialidad y el bienestar del estudiantado.

Referencias

Shodolamu, Opeyemi (2025). *Student depression dataset*. Kaggle. <https://www.kaggle.com/datasets/hopesb/student-depression-dataset/data>

Scikit-learn developers. (2024). *sklearn.ensemble.RandomForestClassifier* (v1.5). Scikit-learn documentation. <https://scikit-learn.org/1.5/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

Scikit-learn developers. (2024). *sklearn.linear_model.LogisticRegression* (v1.5). Scikit-learn documentation. https://scikit-learn.org/1.5/modules/generated/sklearn.linear_model.LogisticRegression.html